

Pipeline MLOps pour la Classification d'Images Cytologiques

Projet M2 SID – 2025/2026

Aix-Marseille Université

Master 2 – Sciences et Ingénierie des Données



Membres du groupe :

- EL HANA Amine
- LAKHZOUM Sarah
- NESSAS Abdelbadie

Encadrante : Feda Almuhsen

Date de rendu : 12 décembre 2025

Table des matières

1	Introduction	2
2	Le Dataset SipakMed	3
2.1	Catégories du dataset	3
3	Architecture du Pipeline MLOps	4
3.1	Git : versionnage du code	4
3.2	DVC : gestion des données et des modèles	4
3.3	MLflow : Suivi et Analyse des Expériences	4
3.3.1	Comparaison des Expériences	5
3.3.2	Sélection du Meilleur Modèle	5
3.3.3	Meilleurs Hyperparamètres (Résultat MLflow)	5
3.4	Explicabilité : LIME, SHAP, Grad-CAM	7
3.5	Interface Streamlit	7
4	Modèles Testés et Résultats	8
4.1	Performances	8
5	Conclusion et Perspectives	9

1 Introduction

Dans le cadre du Master 2 SID, l'objectif de ce projet est de transformer un modèle de Deep Learning traditionnel en un système complet conforme aux bonnes pratiques du MLOps. Les modèles classiques souffrent souvent de limitations structurelles : absence de versionnage, manque de traçabilité, difficultés de collaboration et faible reproductibilité.

Ainsi, nous avons construit un pipeline moderne intégrant Git, DVC, MLflow, des outils d'explicabilité, ainsi qu'une interface utilisateur Streamlit, permettant un flux complet allant des données au déploiement.


2 Le Dataset SipakMed

Le dataset SipakMed contient 4049 images cytologiques issues de frottis cervicaux. Il est divisé en :


- 80% pour l’entraînement ;
- 20% pour le test.

2.1 Catégories du dataset


- **Abnormal** : cellules anormales ;
- **Benign** : cellules bénignes ;
- **Normal** : cellules normales.



Abnormal
Cellules avec anomalies



Benign
Cellules bénignes



Normal
Cellules normales

Ce dataset permet d’entraîner des modèles de classification adaptés au contexte médical.

3 Architecture du Pipeline MLOps

Le pipeline repose sur plusieurs briques technologiques complémentaires.

3.1 Git : versionnage du code

Git garantit une collaboration fluide et un suivi structuré des modifications, tout en rendant le code plus modulaire.

3.2 DVC : gestion des données et des modèles

DVC permet de versionner les données, les modèles et le dossier `mlruns/`. Il assure la reproductibilité complète et la synchronisation via un remote partagé.

3.3 MLflow : Suivi et Analyse des Expériences

MLflow a été utilisé comme outil central pour la gestion, l'organisation et la comparaison de l'ensemble des expériences réalisées durant le projet. Il a permis une traçabilité complète depuis la configuration des modèles jusqu'à l'évaluation finale. Grâce à son interface, chaque expérience est automatiquement documentée et peut être consultée ou reproduite ultérieurement.

MLflow assure notamment les fonctionnalités suivantes :

- journalisation automatique de tous les hyperparamètres utilisés (learning rate, batch size, dropout, etc.) ;
- suivi en temps réel des métriques d'entraînement et de validation ;
- sauvegarde du modèle à chaque expérience ;
- comparaison visuelle de toutes les expériences effectuées ;
- analyse de l'évolution des performances au fil des epochs.

3.3.1 Comparaison des Expériences

Plusieurs expériences ont été réalisées pour chacun des trois modèles testés : ResNet50, EfficientNetB0 et MobileNetV2. À travers l'interface MLflow, il est possible d'observer et comparer directement :

- l'accuracy globale,
- le F1-score de la classe *Abnormal*,
- l'AUC,
- la loss d'entraînement et de validation.

Les graphiques fournis dans MLflow ont mis en évidence la nette supériorité du modèle ResNet50 sur les autres architectures. Un exemple de comparaison des métriques est illustré en Figure 3.4.

3.3.2 Sélection du Meilleur Modèle

L'analyse comparative réalisée avec MLflow a permis d'identifier clairement **ResNet50** comme le modèle offrant les meilleures performances globales. Les différentes expériences menées montrent que ce modèle présente :

- une **accuracy de 92 %**,
- un **AUC de 0.9960**,
- un **F1-score de 91 %** pour la classe *Abnormal*.

Ces résultats sont significativement supérieurs à ceux obtenus avec EfficientNetB0 et MobileNetV2, comme le montrent les visualisations précédentes. L'ensemble de ces observations a conduit à retenir ResNet50 comme modèle final du pipeline.

3.3.3 Meilleurs Hyperparamètres (Résultat MLflow)

Les hyperparamètres optimaux du modèle ResNet50 ont été identifiés via MLflow. La figure 3.3 présente la configuration du run ayant obtenu les meilleures performances.

Les paramètres optimaux sont résumés ci-dessous :

- **batch_size** : 32
- **learning_rate** : 0.001
- **dropout** : 0.5
- **dense_units** : 256
- **freeze_backbone** : True (Phase 1)
- **fine-tuning** : Activé en Phase 2
- **image_size** : 224×224
- **epochs** : 8




FIGURE 3.1 – Comparaison de l'accuracy entre les modèles ResNet50, EfficientNetB0 et MobileNetV2.




FIGURE 3.2 – Comparaison du F1-score (classe Abnormal) entre les modèles testés.

Parameter	Value
batch_size	32
class_names	['Abnormal', 'Benign', 'Normal']
dataset	sipakmed_new6
dense_units	256
dropout_rate	0.5
epochs	8
freeze_backbone	True
image_size	224x224
l2_reg	0.01
learning_rate	0.001
model_type	resnet50

FIGURE 3.3 – Meilleurs hyperparamètres obtenus pour le modèle ResNet50.

Cette configuration représente le meilleur compromis entre stabilité, vitesse d'apprentissage et capacité de généralisation.

3.4 Explicabilité : LIME, SHAP, Grad-CAM

Pour comprendre les décisions du modèle :

- **LIME** explique localement via des superpixels ;
- **SHAP** calcule la contribution des features ;
- **Grad-CAM** génère des cartes de chaleur montrant les zones importantes.

3.5 Interface Streamlit

Une interface utilisateur moderne a été développée pour téléverser des images, afficher les prédictions ainsi que les heatmaps Grad-CAM.




FIGURE 3.4 – Interface de streamlitt.

4 Modèles Testés et Résultats

Trois modèles ont été comparés :

- ResNet50 ;
- EfficientNetB0 ;
- MobileNetV2.

4.1 Performances

Modèle	Accuracy	AUC
ResNet50	92%	0.9960
EfficientNetB0	88%	0.9134
MobileNetV2	67%	0.5869

TABLE 4.1 – Performances des modèles sur SipakMed.

ResNet50 se distingue comme le meilleur modèle grâce à sa précision et sa stabilité.

5 Conclusion et Perspectives

Nous avons développé un pipeline MLOps complet, incluant versionnage, suivi, explicabilité et déploiement. Le modèle ResNet50 atteint 92% de précision, avec un AUC de 0.996.

Perspectives

- Dockerisation de l'application ;
- Intégration d'une API (FastAPI) ;
- CI/CD ;
- Enrichissement du dataset ;
- Documentation finale.